

F9. Benchmark-estimand alignment matrix

Benchmarks are diagnostic only when they help to test the same latent event.

	Observability	Selection utility	Exposure	Fusion	Faithfulness
Supporting-fact QA HotpotQA, 2Wiki, IIRC	high	med	low	low	low
Shortcut-resistant QA MuSiQue, MoreHopQA	high	med	low	low	low
Path / process QA EntailmentBank, eQASC	low	med	low	high	med
Heterogeneous evidence HybridQA, MultiModalQA	low	med	low	high	low
Long-context multi-hop LongBench, NovelHopQA	low	low	high	med	low
Fact verification FEVER, HoVer, SciFact	low	low	low	med	high
RAG-specific diagnostics FRAMES, MultiHop-RAG	med	med	med	med	med
Counterfactual QA CofCA variants	low	low	low	med	high
Agentic / tool-use ToolBench, WebArena	med	med	low	med	med

Strong empirical coverage should include at least one observability/shortcut benchmark and one faithfulness or counterfactual diagnostic.